实验已走到 serving 机制层。
论文应回答：推理验证何时可信？

建议题目 IVGym: Inference Verification under Serving Variability

34 / 64

真实 NF4 被检出

token-DiFR；128 tokens / 序列

1,200

vLLM 正式测量请求

600 pilot + 600 同输入时间复测

26 / 26

调度诊断运行通过验证

Nsight / PyTorch / 无 profiler

核心判断：机制证据已形成；部署误报率、跨条件泛化和验证成本尚未闭环。

主线建议：用真实 serving 变化定义检测边界，再验证有适用条件的审计方法。

最新进展：六条证据链已归档，联合验证仍待完成

“完成”指该实验协议完成；各项测量的模型、样本与统计单位不同。

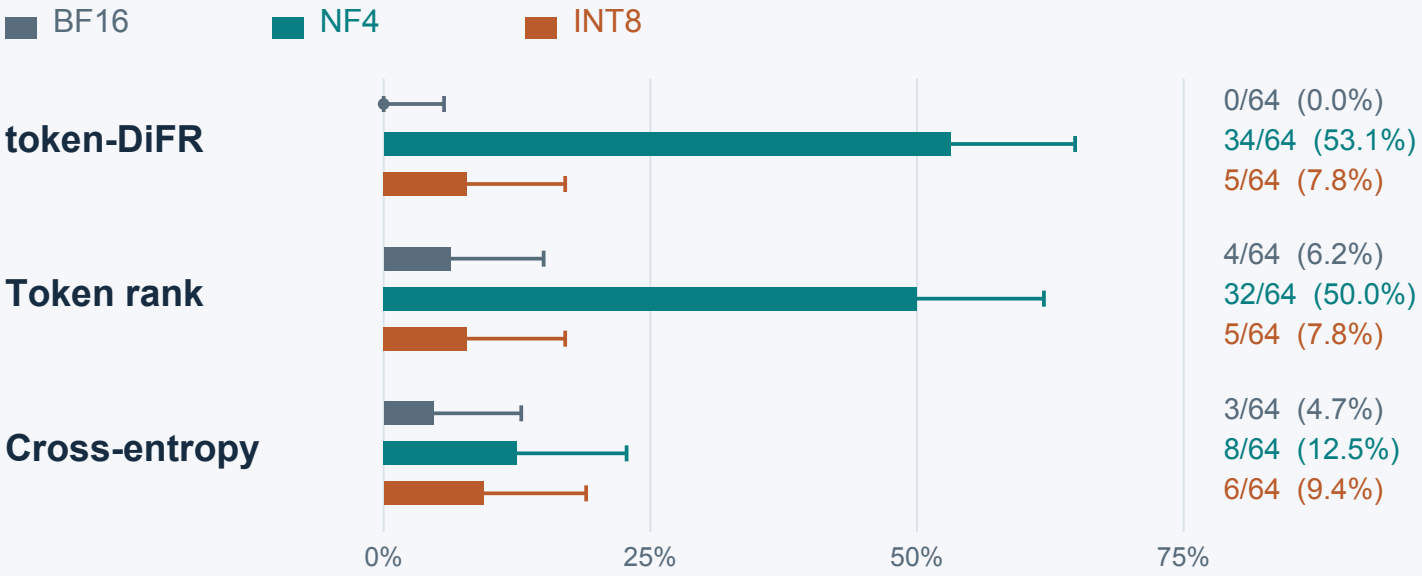
实验 / 日期	已完成的证据	目前可以支持的结论
H100 + A100 / 10.16-17	8 项 / 4 项硬件基线	建立独立基线；不能直接相减当配对结果
配对回放 / 10.18	80 × 256 固定 tokens；4 schedules	诚实数值漂移依赖执行路径
真实量化 / 10.18	BF16 / NF4 / INT8；每臂 32 校准 + 64 测试	NF4 有信号；INT8 在当前预算下较弱
本地机制 / 10.19	524 本地测量 + 42 HTTP + 96 SDPA 控制	合法表示与 kernel 也改变耗时
vLLM serving / 10.19	600 + 600 请求；缓存 / 并发 / eager 控制	上下文响应可复测，幅度取决于 serving
调度追踪 / 10.19	26 次运行；98 请求；2K / 8K token budget	早期到达间隔包含 prefill / 调度贡献

下一条必须补齐的证据链：独立校准 → 合法条件误报 → 攻击检出 → 端到端成本。

真实 NF4 已有检测信号；INT8 仍是难点

Qwen3-1.7B / L40S；32 条 BF16 校准；每臂 64 条测试；每条 128 tokens；名义 α = 5%。

拒绝率（BF16 为误报；NF4 / INT8 为检出）



误差线：95% Wilson 区间。token-TOPLOC 为仓库内 rank score。

结果的适用边界

DiFR 需共享 RNG 协议。
TOPLOC 不需共享 seed，
但 BF16 误报为 4/64。

DiFR 的 0/64 误报：
95% Wilson 上界仍为 5.66%。

内部激活控制：NF4 64/64、INT8 52/64；需要 provider 额外证据，须单独报告。

real_quantization_l40s_20261018/pilot/summary.json | report: real_quantization_l40s_20261018.md

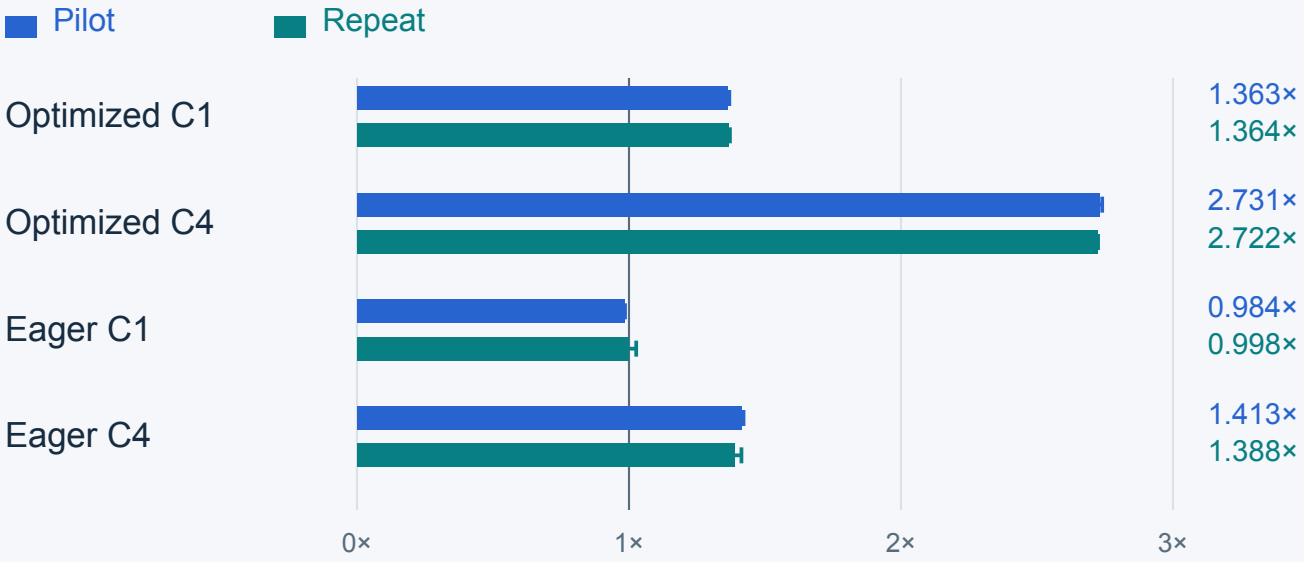
2026-10-20 · archived through 2026-10-19 · 57ceb5e

已测量

计时信号能穿过 vLLM，但依赖执行模式与流位置

同一 L40S 的 loopback streaming；每轮 600 请求；延迟 18.25 分钟后用相同输入复测。

16K full / truncated：首事件后的 ms/token 比



合法 prefix cache：cold / hit

8K / C = 4	Pilot	Repeat
早期 0-32	**1.66×**	**1.66×**
后期 32-127	**0.99×**	**0.99×**

前段差异明显，后段接近 1。
误差线为范围；全部是同机复测。

小计时差不能直接判为截断；快首 token 也可能来自合法缓存命中。

vllm_serving_l40s_20261019/summary.json | vllm_serving_l40s_20261019.md

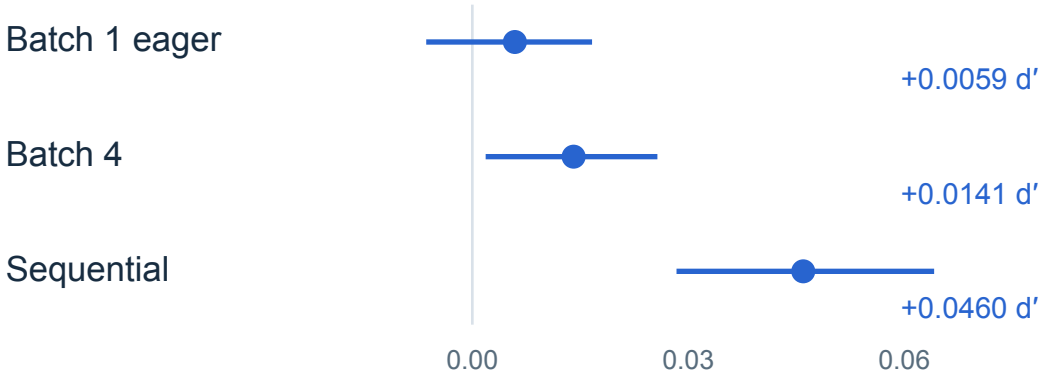
2026-10-20 · archived through 2026-10-19 · 57ceb5e

已测量

合法系统变化会移动两类观测量

Token：固定输出也会换分数。Clock：早期流包含调度效应。

H100 → A100：诚实 token-DiFR 漂移



90% 配对序列 bootstrap；仅一次 GPU/driver 对比

调度预算改变：2,048 → 8,192

prefill / generation 混合迭代	**13 → 4** 次
早期到达间隔	**16.93 → 13.70** ms/token
后期到达间隔	**11.02 → 11.10** ms/token

Nsight；8K / C4 / cache cold；两组中位数

论文中的 honest null 必须覆盖允许的执行条件；单一参考分布不足以证明部署可靠性。

cross_gpu_replay_20261018/summary.json | scheduling_l40s_20261019/summary.json

2026-10-20 · archived through 2026-10-19 · 57ceb5e

已有测量框架；核心技术贡献尚未建立。

最新文献已覆盖混合校准与 vLLM 集成；新主线见 BF16 技术补充 slides。

探测请求

长 / 短 context
新鲜 prompt / 固定预算

›

采集证据

tokens + SSE 到达时间
精确记录事件合并

›

适用条件 + 校准

覆盖合法 serving 变化
冻结统计量与阈值

›

输出审计结论

异常 / 未见异常
证据不足 → inconclusive

C1 / 已有证据

可识别性的边界

量化、上下文与合法优化
分别改变哪些观测量？

C2 / 部分实现，待验证

有适用条件的审计

校准何时可用？
何时应返回证据不足？

C3 / 待补主实验

检出率与成本的权衡

固定误报率下
比较通道、预算和重算成本。

技术复审：单靠上述框架不足以形成新贡献；需验证新的采样边界建模与复算收益。

10 页正文：每一节只承担一个可验证的论点

章节分配仅为框架；新的技术命题与优先实验见 BF16 技术补充 slides。

章节	页数	必须回答的问题	主图 / 证据
1 Introduction	1.0	为什么真实 serving 使验证不可靠？	F1 合法变化与攻击的观测重叠
2 Problem / Model	1.0	谁可信？可见什么？允许哪些优化？	通道与威胁模型表；分开 RNG / 激活
3 Characterization	2.0	变化来自数值、执行还是调度？	F2 量化；F3 serving；F4 调度
4 Design	1.5	怎样选统计量、校准和拒绝判定？	架构；算法；适用条件（待验证）
5 Evaluation	3.5	固定误报率下，检出率和成本如何？	F5 TPR / FPR / cost 曲线（待补）
6 Related / Limits	1.0	比已有工作多了什么？何时失败？	相关工作对照；迁移与适应性攻击

旧稿需重写：单 H100 叙事 → 多层 serving 证据；“模型身份证明” → 有条件的行为异常检验。
将真实量化与模拟扰动分开；将测量成本、请求成本和参考重算成本分开。

官方格式：10 页双栏；附录单独提交；参考文献后须附 AI Usage Disclosure。

先补最能改变论文结论的实验

下面均为建议，尚未运行。先控制误报，再判断是否值得增加检测复杂度。

P0	**独立校准 + must-not-flag**	冻结窗口；新 prompt / session；覆盖 eager、缓存、并发。 判据：各合法条件 FPR 的 95% 上界 ⩽ 5%。
P1	**同请求通道消融 + 预算曲线**	token / clock / 联合；128 / 512 / 2048 tokens；报告重算与请求成本。 判据：相同 FPR 下，TPR 或成本确有改善；否则删减设计。
P2	**跨条件迁移 + 实际量化扩展**	新语料、额外 GPU / 模型；匹配真实 NF4 / INT8，随后 AWQ / GPTQ。 判据：区分阈值迁移成功与需重新校准的条件。
P3	**适应性 provider**	加入延迟填充与 probe 识别；允许输出 inconclusive。 判据：明确可绕过的范围与审计适用边界。

MLSys 2027 CFP：10 月 30 日 20:00 UTC 截稿（北京时间 10 月 31 日 04:00）。