BF16 还未解决。
核心创新需要重新收敛。

已有实证基础；“校准 + 多硬件 + 接 vLLM”不足以成为新的核心贡献。

01

运行可重复

同一路径复跑一致
不等于不同 shape 一致

02

诚实 BF16 通过

跨 kernel / GPU / 调度
误报率仍需独立验证

03

低精度可检出

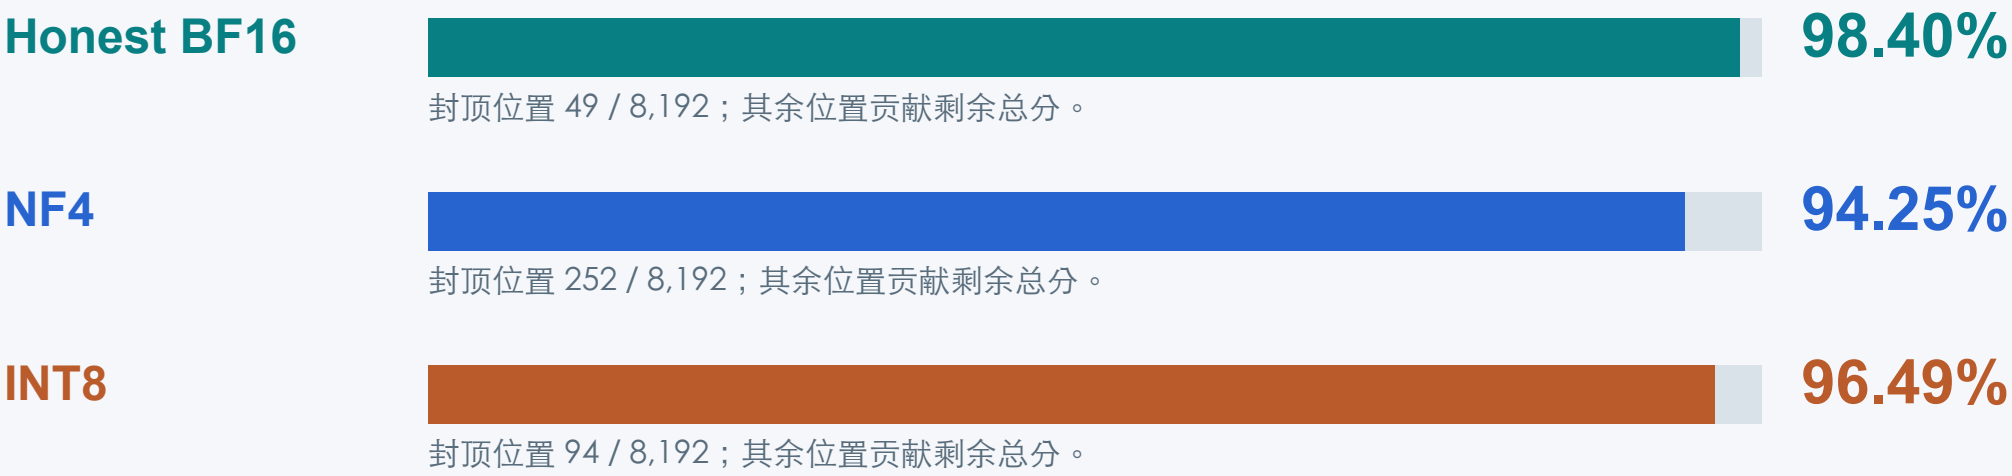
真实 INT8 仅检出 5/64
不够支撑广泛可靠性

合理目标：检验明确契约下的行为一致性；不能由 token 无条件证明物理精度。

DiFR LLM-42 Bit-Exact

49 个封顶位置，贡献了诚实 BF16 总分的 98.4%。

64 条 × 128 tokens 的原评估切分。少量极端分数值得优先归因。



代码中：候选被 top-k/top-p 排除 → 分数直接记为 30。

线索：过滤边界可能放大小误差。下一步要记录原始 logits 与两端候选集。

先把协议差异与硬件误差分开。

BF16 dtype 不是完整数值契约；输出差异可能在多个环节产生。

执行路径

GEMM / split-KV
归约、cast、SFU

数值误差

冻结 prefix 后
定位 logit 变化

过滤边界

top-k / top-p
候选集离散跳变

采样分数

共享随机数下
从 0 跳到封顶

先做同 logits 的 golden replay，再讨论 GPU 机制。

逐项对齐 float32/64 过滤、top-p 边界约定、tie-breaking 和 RNG。
当前 top-p 注释与代码不一致；修订协议后必须重新校准。

本次未修改采样器。若只是协议问题，修复基线；不包装成硬件创新。

对比必须包括最接近的方法，并匹配可获得的信息。

本地 token_toploc 是 token rank 基线，不能当作原版 TOPLOC 或 RUT。

方法 / 信息	已经做到	我们必须新增什么
DiFR 共享 RNG	margin / likelihood / 高斯模拟 合法配置混合校准 + vLLM	比通用噪声更紧的采样边界建模 同误报下更好的能力—成本
RUT 无共享 RNG	以本地参考样本校准秩统计 面向黑盒行为分布	单列 seed-free 对照 参考采样不是免费
TOPLOC / Act-DiFR 需要 provider 激活	中间状态的压缩指纹比较	单列合作式验证条件 不能用额外状态暗中增强 token-only

“混合校准 + 新打分 + 接 serving”不足；要证明机制建模带来独立收益。

DiFR RUT TOPLOC

DiFR (2025) | TOPLOC (2025) | RUT (2025 / ICLR 2026)

2026 年工作已深入到归约树、指令语义与精确回放。

硬件知识应成为方法的约束和干预手段；仅指出浮点非结合性已经不够。

LLM-42 · 2026	快速解码 + 固定形状窗口验证 / 回滚	固定窗口回放本身已有先例
Hawkeye · MLSys 2026	Tensor Core matmul 数值建模 / CPU 回放	从实际归约与舍入语义入手
Bit-Exact · 2026-06	Tensor Core、SFU、cast 与模型块精确回放	对照完整回放的执行信息与成本
Taming Bitwise · 2026-09	归约描述、编译约束、静态验证 / 等价类	机会在跨层到采样的组合

候选空白：把底层数值约束组合成采样决定，并让按需验证确实省成本。

Tensor Core Models　　Batch invariance

primary papers; June / September works below are preprints

从一个参考分数，走向“合法数值变化能否产生这个 token？”

候选方案：考虑候选集变化的数值一致性验证。尚未实现或验证收益。

固定候选集：先解决可控子问题

$$z[j] = logit[j] + T * g[j]$$

合法变化下，z[j] 位于区间 [L[j], U[j]]。

若某个合法竞争者： L[j] > U[y]

则 claimed token y 不可能获胜。
区间重叠 → 仍有歧义，不能直接判通过。

难点：top-k / top-p 的离散边界

- 同时约束 logit 与候选成员资格
- 保留跨层误差相关性，避免区间膨胀
- 剪枝不可能的候选集；歧义触发复算
- 无法收紧时输出 inconclusive

核心区别必须来自边界建模与误差约束；DiFR 已有 Gaussian Monte Carlo。

用硬件机制缩小不确定性，把复算花在能消除歧义的位置。

这不是“多加几次 replay”：必须测出相同错误率下的验证成本收益。

01

合法执行目录

GPU / kernel / shape
归约、cast、采样协议

02

一次参考 pass

估计数值不确定性
判定支持集是否稳定

03

按需精确回放

歧义位置 / 窗口
复用可信 prefix 状态

04

冻结规则评估

异常 / 未排除 / 拒判
独立校准与测试

成本陷阱：回放一个 token 也可能要重建整个 prefix / KV。
信任陷阱：未知执行类别不能只凭 provider 自报来缩小。

要同时报告检测能力、拒判率、参考 GPU 时间，以及缓存与校准成本。

把系统知识变成干预实验；clock 暂作辅助证据。

现有调度与缓存结果有价值，但尚未证明跨部署可辨识的 timing 签名。

vLLM / FlashInfer	固定 batch 归约或 split-KV 合并	数值差异能否随干预消失？
Sarathi-Serve	chunked prefill 与 decode 交错	13 → 4 次混合迭代是否解释早窗？
FlashAttention-4	TMEM、异步 MMA、softmax / exp 瓶颈	避免只用逻辑字节数解释 timing

尚缺硬件计数器与充分的单因素控制；量化加速、纯带宽模型都不能预设。

vLLM FlashInfer FlashAttention-4

vLLM / FlashInfer docs | Sarathi-Serve (2024) | FlashAttention-4 (2026)

先做三组能决定方向的实验。

收益必须在相同信息条件、相同误报约束和独立测试上成立。

P0

定位 49 个 BF16 封顶事件

记录两端 logits、候选集、边界、margin；先对齐采样协议。

若主要是协议差异 → 修复并重跑基线，不宣称硬件创新。

P1

冻结输入，只干预一个数值机制

GEMM shape / 归约 / attention split；用确定性路径作对照。

若误差与具体机制关联很弱 → 不扩展昂贵的全栈建模。

P2

测能力—成本曲线与消融

DiFR 各变体、完整回放、候选方法；真实 NF4 / INT8。

若同时抹掉攻击信号，或复算不省成本 → 该主线失败。

指标：逐条件 FPR 上界、TPR、拒判率、审计 GPU 时间；新语料与独立 session。

论文围绕一个问题写：能否既容忍合法 BF16，又保留量化信号？

暂定方向：Sampling-Aware Verification of BF16 Inference under Execution Variability

OBSERVATION

解释误报的来源

协议控制 → 过滤边界 → 硬件机制
不要只展示“不同 GPU 有差异”

METHOD

提出新的判据与实现

候选集感知 + 受约束误差模型
歧义驱动复算，明确成本与适用范围

EVIDENCE

验证独立增益

固定 FPR，比 TPR / GPU 时间
真实量化 + 合法执行变化 + 消融

目前可以写问题和机制；核心方法与收益必须靠下一轮实验决定，不能预写结论。

已交付：技术评审、最新文献对照、离线分数诊断与 10 页可编辑 slides。